五因子线性预测：训练样本与损失函数比较

JHSS_QUANT 研究报告 | 2026 年 11 月 1 日

摘要

本文在固定线性预测结构与给定数据范围内，比较正则化、训练标签变换、损失函数及训练样本处理对截面预测效果的影响，共完成 18 项实验配置。研究采用同评价股票池与同训练样本消融，识别特征选择和样本筛选的混杂影响，并通过组合实验检验改进的可叠加性。

主要发现：三特征 OLS 的初始优势在固定训练样本后消失，原改善主要对应训练样本扩大。对波动率缺失的训练输入填 0 后，五特征 OLS 的测试平均 IC 从 0.012861 升至 0.018384；在该基线上，已检验的 Ridge、Lasso 与 MAE 均未取得进一步的测试均值增益。考虑逐日相关性后，正平均 IC 的统计证据仍有限。

1. 研究设定与基准定义

项目	实验设定
预测结构	预测值 = Xβ + b。输入为原始股价、成交金额、总市值、换手率、二十日波动率；沿用给定 rank zscore 处理，不引入外部数据。
正式标签	Y = C(t+5) / O(t+1) / 5，按题目定义，不减 1；t+1、t+5 按全市场交易日历定位。
训练与验证	2012-2018 年为训练期。需要验证的配置以 2018 年为内部验证期，依据验证 IC 选 alpha 后，在完整训练期重训。
测试口径	2019-2020 年；共同五特征完整评价池，共 1,366,724 行、482 天。逐日计算 Pearson IC，再对日期等权平均。
基准 B0	五特征 OLS，训练时删除所需输入或标签无效的行，最终训练样本 3,352,997 行。
基准 B1	五特征 OLS，仅将训练波动率缺失值填 0，最终训练样本 3,638,573 行；验证与测试池与 B0 一致。

题目未指定缺失值处理方法，故显式报告 B0 与 B1 两种基准。B0 与 B1 的比较属于训练数据处理的敏感性分析；损失和正则化方法的增量效果分别在相应基准下评价。三特征模型仅用于诊断性消融，最终比较对象保持五个输入。

研究设计

围绕三个问题组织实验：① Lasso 压零变量是否支持删去相应特征；② 初始三特征优势是否由训练样本变化解释；③ 缺失填补与正则化、MAE 的收益能否叠加。正文报告关键对照与结论，附录给出实现架构和完整实验表。

2. 特征消融：分离变量数与样本构成

研究假设 H1：减少换手率与波动率输入，可改善线性预测表现。

以 B0 为起点，Ridge 的测试结果与 OLS 几乎一致。Lasso 经内部验证选取 alpha=1e-4，测试平均 IC 为 0.014484，并将换手率和二十日波动率系数压为 0。基于这一稀疏解，进一步构造只含原始股价、成交金额和总市值的 OLS，以检验减少输入的效果。

配置	训练行数	验证 IC	测试 IC
B0：五特征 OLS	3,352,997	0.041747	0.012861
三特征 OLS：按实际输入清洗	3,638,573	0.042243	0.015740
三特征 OLS：固定 B0 训练行	3,352,997	0.041071	0.012845

2.1 初始观察与混杂因素

三特征 OLS 的测试平均 IC 比 B0 高 0.002879，但训练集增加了 285,576 行。原因是波动率不再作为输入，其缺失也不再触发训练删行。因此，初始比较同时改变了模型输入与训练样本，无法识别减少特征的独立效果。

2.2 同训练样本对照

新增 sample_rule=complete_5f：先按原五特征完整性筛选，再将前三列交给模型。该配置与 B0 使用相同训练股票-日期键及评价池。控制样本后，三特征测试 IC 为 0.012845，与 B0 接近且略低，验证 IC 同时下降。

结论：H1 未获得同样本对照支持。三特征自然清洗版本的提升对应训练样本扩大，而非单纯删去两个输入。该结果将后续研究重点从变量删减转向训练样本保留。

2.3 特征选择对训练分布的依赖

Lasso，alpha=1e-4	原始股价	换手率	波动率
删除缺失行	-0.000016	0	0
训练波动率填 0	0	-0.000235	0.000136

扩样本后，Lasso 保留换手率与波动率，而将原始股价系数压为 0。零系数反映给定样本、损失与惩罚下的条件选择，不足以单独证明变量不含预测信息。对特征贡献的判断应以样本一致的消融为依据。

3. 缺失输入处理与训练样本保留

研究假设 H2：保留波动率缺失记录，可改善五特征 OLS 的估计。

B1 在标准化输入尺度上将训练波动率缺失值填为 0，其余四个输入与标签保持原值，验证和测试池不变。相对 B0，测试平均 IC 增加 0.005523，std_IC 从 0.115780 降至 0.109039；验证 IC 从 0.041747 升至 0.042311。填 0 是常数插补，不涉及历史波动率重算。

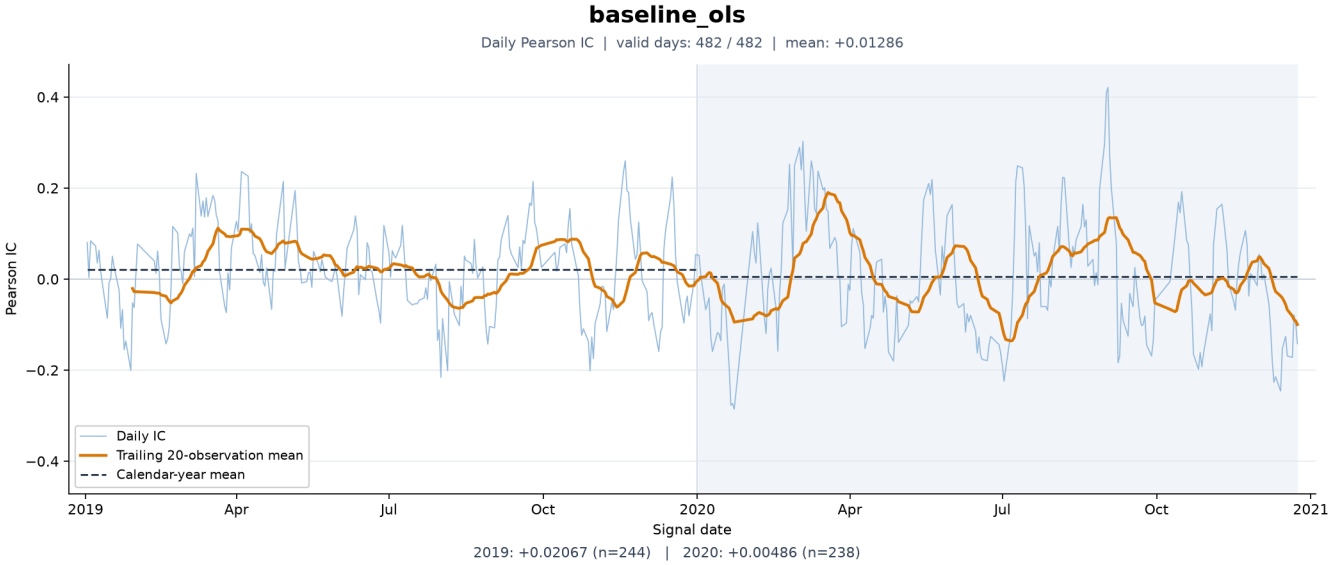


图 1 B0 的逐日 IC、后向 20 个观测日均值与年度均值。来源：baseline_ols 的保存结果。

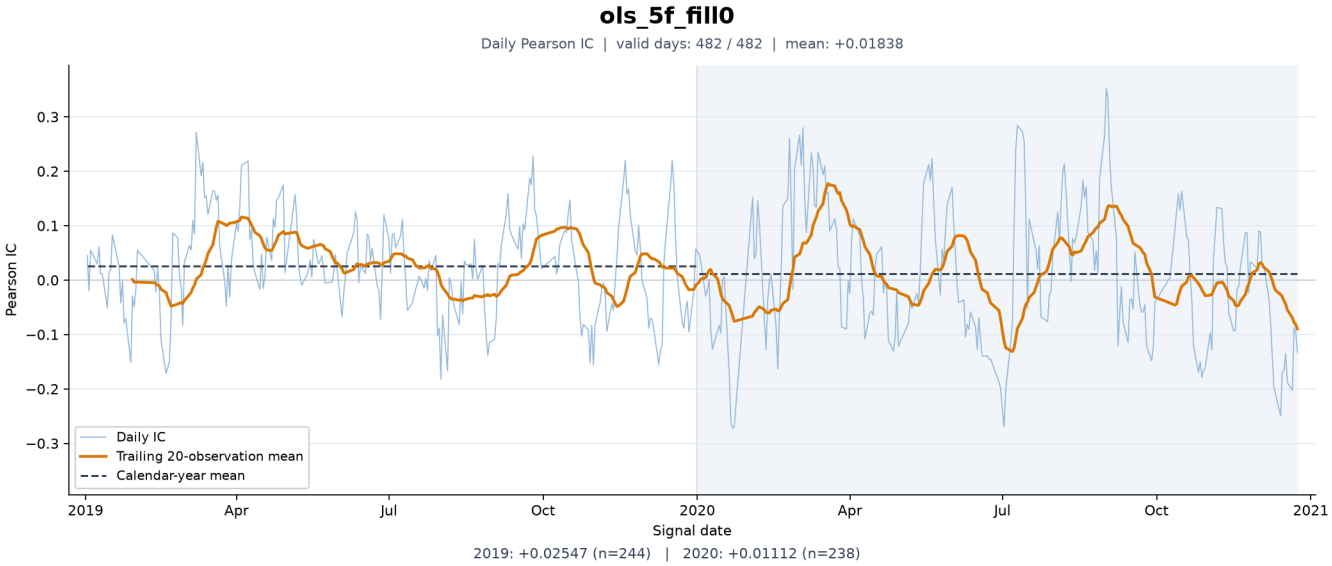


图 2 B1 的对应时间序列。来源：ols_5f_fill0 的保存结果。原图纵轴范围不同；离散程度以 std_IC 数值比较。

新增训练样本共 285,576 行、2,848 只股票，覆盖全部 1,696 个有效训练日，缺失均来自波动率。新增样本 Y 的标准差为 0.02069，原完整样本为 0.01320，说明保留样本同时改变了训练分布。

结果支持保留缺失记录这一处理在当前评价期的相对优势，但尚不能区分样本数量与样本构成的贡献，也未验证 0 是否为最优填充值。缺失成因和新增样本的影响度仍需进一步分析。

4. 损失函数与正则化的增量效果

研究假设 H3：在 B1 上应用正则化或 MAE，可进一步改善预测。

五特征模型	验证 IC	测试 IC	std_IC
B0：删除缺失行，OLS	0.041747	0.012861	0.115780
删除缺失行，MAE	0.038999	0.016853	0.125070
B1：训练填补，OLS	0.042311	0.018384	0.109039
训练填补，MAE	0.039687	0.018163	0.124477
训练填补，Ridge	0.042583	0.018041	0.111249
训练填补，Lasso	0.042371	0.016814	0.114949

4.1 MAE 与填补的交互

在删除缺失行的样本上，MAE 相对 OLS 的测试 IC 增益为 0.003993；扩样本后，该差值为 -0.000221，且 MAE 的 std_IC 约比 B1 高 14.2%。两种单项处理没有表现出可加的收益。平均 IC 差值较小，结果支持“未见额外优势”，而非统计意义上的显著劣化。

一种可能机制是：新增样本改变了特征与标签的关系，而 MAE 对大残差的相对权重低于 MSE，从而产生不同的系数调整。该解释尚未通过残差分组或影响度分析验证；新增样本标签方差较大本身不等于拟合残差较大。

4.2 正则化未带来测试期增益

填补 Ridge 与 Lasso 的验证最优参数分别为 0.1 和 1e-4，验证 IC 略高于 B1，测试 IC 则分别为 0.018041、0.016814，均低于 B1。结论限于已搜索网格；填补 Lasso 未覆盖 0 及小于 1e-4 的弱惩罚区域，较强惩罚候选还出现无有效 IC。

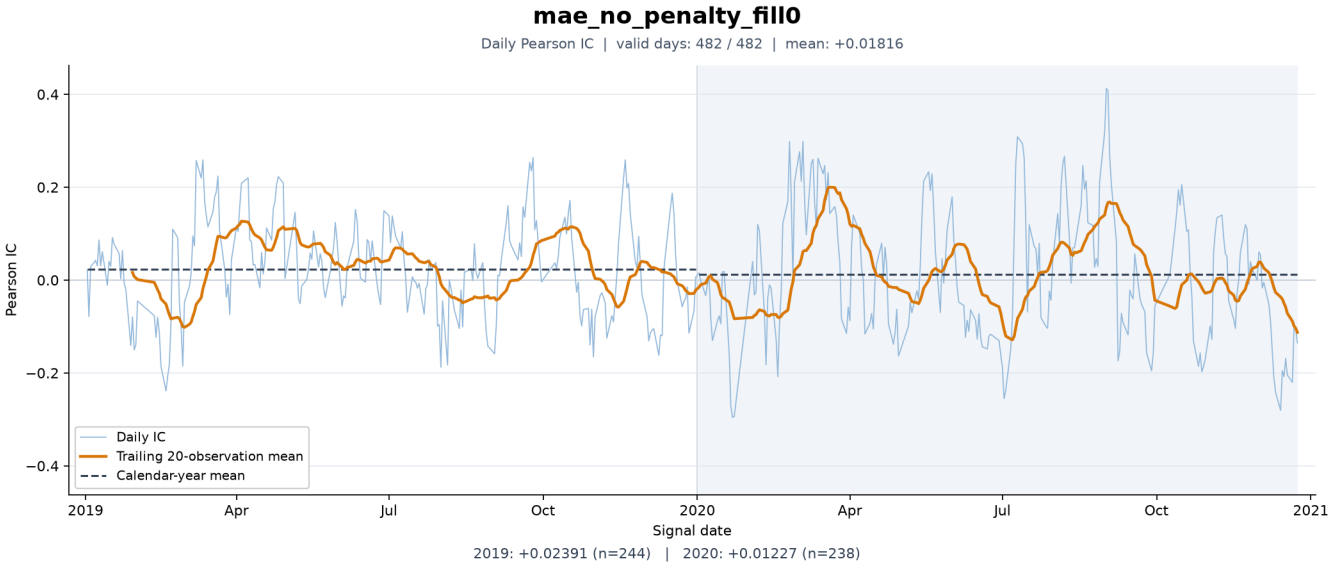


图 3 训练填补 MAE 的逐日 IC。与图 2 相比，测试均值接近，但逐日 IC 离散程度更高。

5. 跨年表现与统计不确定性

对保存的日度 IC 进行补充诊断；不据此重新选择 alpha。

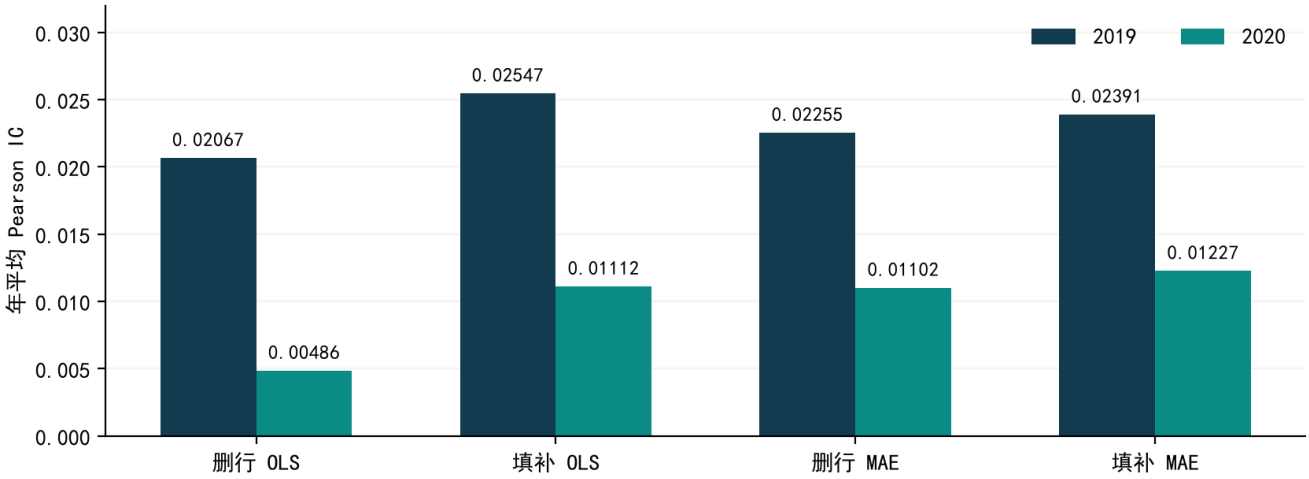


图 4 分年平均 IC。2019 年含 244 个有效日期，2020 年含 238 个有效日期；各年内按日期等权。

B1 在 2019、2020 年均优于 B0，年均 IC 分别为 0.025472、0.011117。填补 MAE 相对 B1 的差值在两年分别为 -0.001565、+0.001157，表明方法排序存在时期差异。2020 年各模型的绝对 IC 水平均低于 2019 年。

5.1 序列相关下的均值检验

B1 的正 IC 日期占 57.1%，IC 一阶自相关约 0.815。正式标签的未来收益窗口重叠，日度统计亦表现出明显持续性。因此，对平均 IC 的推断采用日度序列的 HAC 标准误，以 5 和 20 个交易日滞后进行敏感性检查。

模型	独立假设 t	HAC(5) t	HAC(20) t
B0：删行 OLS	2.44	1.23	1.02
B1：填补 OLS	3.70	1.87	1.55
填补 MAE	3.20	1.62	1.32

B1 的 HAC(20) 均值 t 值为 1.55，近似 95% 置信区间为 [-0.00481, 0.04158]；HAC(5) 区间同样包含 0。评价期内的正平均 IC，尚不足以确认稳定的样本外预测能力。

采用 Newey-West / Bartlett 权重及大样本正态近似，未作小样本修正。该诊断未校正模型筛选和反复查看评价期的影响，因而作为探索性证据报告。统计证据不足不等同于确认真实信号为零。

5.2 评价范围

std_IC 用于描述逐日相关的离散程度，不代表投资组合风险。本研究未包含组合构建、换手、交易成本或风险暴露分析，故结论限于截面预测指标。相对 B0 的改善与平均 IC 可靠地大于零，是两个不同的统计问题。

6. 结论与研究边界

依据控制变量实验区分数据处理效应、模型效应与统计证据。

6.1 研究结论

（1）**训练样本控制改变了特征选择结论。**三特征 OLS 的初始优势在固定训练行后消失，不能归因于删除换手率与波动率。Lasso 稀疏解在扩样本后改变，进一步说明变量选择依赖训练分布。

（2）**缺失记录保留是当前主要改善来源。**在固定评价池下，B1 的平均 IC 比 B0 高 0.005523，两个测试年份均有改善。新增记录覆盖整个训练期，且标签分布与原完整样本不同。

（3）**组合方法未形成进一步优势。**在 B1 上，已验证的 Ridge、Lasso 和 MAE 未超过其测试平均 IC；标签日标准化与按日损失也未在原完整样本上产生较大均值增益。最优记录仍为简单的五特征填补 OLS。

6.2 方法限制

缺失值处理未在题目中指定，本文将其作为基准敏感性问题单独披露，而不将预处理差异直接认定为指定改进方向上的超基线收益。相对 B1，目前尚无明确的增量改进。三特征配置仅用于分析，不作为最终五输入模型。

2019-2020 年评价结果参与了后续假设形成，因此该时期并非完全独立的最终验证集。正则化网格覆盖有限，部分标签与损失分支也未在 B1 上重验。下一阶段应固定预处理和评价池，以预先设定的滚动时间验证检验 rank 标签、低波动训练样本筛选，以及新增样本的分组贡献。

6.3 复现与辅助工具披露

项目入口：python -m analysis.analysis。实验声明见 analysis/config.py，参数说明见 analysis/manual.md；附录 A 说明实现与验证，附录 B 汇总全部 18 项结果。报告附件的 source_manifest.json 记录所引用结果路径与 SHA-256，汇总快照和逐日序列支持复算表格、年均值与 HAC 诊断。

使用 Codex 辅助实现模块重构、配置接口、测试、结果核对、统计诊断及排版。本文依据保存的实验结果与可复算脚本组织论证；关于缺失机制与损失函数作用的解释均明确标为待验证假说。

参考资料

[1] JHSS_QUANT远程课题1X.docx：任务定义、输入约束与正式标签。
[2] analysis/results/summary.csv 及匹配的 result.json、daily_ic.png：主表与实验图来源。
[3] analysis/data.py、training_data.py、models.py、config.py 与测试目录：实现与边界处理。
[4] Statsmodels，cov_hac 方法文档：Newey-West / Bartlett 协方差估计说明。报告采用独立公式计算均值标准误。

附录 A 实验架构与配置演进

通过统一计算接口与显式配置，保证对照实验的可比性和可复现性。

模块	职责
config.py / analysis.py	集中声明输入、时间窗口和实验；编排内部验证、最终重训与评价。
data.py / splits.py	在完整行情上按市场交易日键构造标签；依据验证、测试边界屏蔽跨界标签。
training_data.py	在当前拟合期构造目标与选择标志，再执行输入填补及清洗；不改变验证、测试股票池。
models.py / selection.py	数组接口求解线性模型；在统一验证窗口内选择 alpha；截距不参与惩罚。
metrics.py / results.py	统一以正式 Y 计算日度 IC；保存配置、系数、搜索记录、逐日结果及依赖指纹。

A.1 实验需求与配置接口的对应

实验阶段	新增或明确的配置能力
基准、正则化与替代损失	分离 loss、penalty、alpha 和 solver；匹配求解器，保持共同线性预测形式。
统一内部验证	alphas 管理候选；单点列表 [0.0] 为固定模型补充同窗口验证，选参后完整重训。
特征与样本消融	feature_columns 控制模型输入，evaluation_pool 固定评价池；complete_5f 固定训练行。
标签变换与按日损失	target 独立于 loss；daily_wls 显式使用清洗后的日期计数，区分标签标准化与日期等权。
缺失填补对照	train_feature_fill 显式声明输入列及常数；只作用于训练，省略时沿用原行为。

A.2 B1 的配置与数据流

```
{
    "name": "ols_5f_fill0", "sample_rule": "all",
    "target": "raw", "loss": "mse", "penalty": "none",
    "alpha": 0.0, "alphas": [0.0], "solver": "ols",
    "evaluation_pool": "common_5f",
    "train_feature_fill": {"二十日波动率": 0.0}
}
```

数据流：当前拟合期 → 屏蔽跨界标签 → 计算 Y_train → 样本筛选 → 非有限值转 NaN → 指定输入填补 → 剩余缺失清洗 → 求解。目标统计在筛选前计算；内部拟合与最终重训独立执行。

加入填补接口时，93 项测试通过；14 个既有配置在同一合成面板上的系数、训练指标、逐日 IC 与选参结果逐项一致。验证重点包括共享数据不被修改、标签不被填补、截止边界有效，以及共同评价池保持不变。

附录 B 完整实验结果

18 项配置均使用 common_5f 评价池；测试行数与有效天数相同。

实验名称	训练集	验证 IC	测试 IC	std_IC
baseline_ols	完整	0.041747	0.012861	0.115780
ols_5f_fill0	扩充	0.042311	0.018384	0.109039
ols_5f_fill0_ridge	扩充	0.042583	0.018041	0.111249
ols_5f_fill0_lasso	扩充	0.042371	0.016814	0.114949
ols_ridge	完整	0.041747	0.012861	0.115782
ols_lasso	完整	0.041786	0.014484	0.117412
mae_no_penalty	完整	0.038999	0.016853	0.125070
mae_no_penalty_fill0	扩充	0.039687	0.018163	0.124477
ols_3f	扩充	0.042243	0.015740	0.113731
ols_3f_ridge	扩充	0.042243	0.015739	0.113731
ols_3f_lasso	扩充	0.042243	0.015740	0.113731
ols_daily_zscore	完整	0.041827	0.013055	0.111073
lasso_daily_zscore	完整	0.041828	0.013243	0.111236
ols_3f_zscore	扩充	-	0.016190	0.111171
ols_3f_same_rows	完整	0.041071	0.012845	0.119381
ols_zscore_daily_equal	完整	0.041849	0.012730	0.109626
ols_zscore_daily_centered	完整	0.041809	0.012589	0.109669
lhalf_no_penalty	完整	0.037526	0.016136	0.124970

训练集“完整”指原五特征完整样本，共 3,352,997 行；“扩充”指 3,638,573 行。三特征自然清洗与五特征填补的输入数不同。ols_3f_zscore 未配置内部验证，故验证 IC 记为“-”。所有指标保留六位小数。

B.1 标签与按日损失分支

daily_zscore 在每个训练日对有效标签作均值-标准差变换，目标统计先于样本筛选；daily_mse 对清洗后的日期等权，daily_centered_mse 进一步对当日输入和标签去均值。相对 B0，这些配置主要降低 std_IC，测试均值未出现较大增益。

B.2 平滑残差 L0.5 分支

lhalf_no_penalty 优化 mean((r²+epsilon²)^(1/4))，epsilon=1e-4，采用 OLS 与常数中位数双初值 IRLS，并按训练平滑损失选择局部解。测试 IC 为 0.016136，低于 MAE 和 B1。该配置作用于残差，不是系数正则；未作全局最优保证。

这些并行分支尚未全部在 B1 上重新检验。daily_zscore 不等同于截面 rank 标签变换；rank 标签与低波动样本筛选不包含在本阶段完成的 18 项配置中。